

Reaktanz auf TikTok: Häufigkeit und Erkennungsgeschwindigkeit

DemocraGPT · LLM-Benchmark zur automatisierten Kodierung psychologischer Reaktanz in politischen TikTok-Kommentaren

- **Sample:** 1200 Kommentare aus 68 Accounts, 16 Parteien, 400 Videos
 - **Design:** Codebook A (binär) × Codebook B (7 Typen) × Condition A (mit Transkript) × Condition B (nur Kommentar) × 3 Modelle
 - **Volumen:** 14,400 Requests
 - **Repo:** github.com/DanielMatterTUM/democragpt-experiments
-

1. Kurzfassung

Reaktanz ist selten. Mit Codebook A und Video-Transkript liegt die Prävalenz zwischen **3.83 % und 6.58 %** der Kommentare — also im niedrigen einstelligen Prozentbereich.

Das Video-Transkript bringt für die Binärentscheidung fast nichts. Der Vergleich Condition A (mit Transkript) gegen Condition B (nur Kommentar) verschiebt die Prävalenz um weniger als zwei Prozentpunkte, und zwar nicht konsistent in eine Richtung. Für eine Erkennungspipeline sind das rund 900 zusätzliche Prompt-Tokens ohne messbaren Gewinn.

Jev ist auf beiden Achsen Sieger: mit **0.35 s** mindestens doppelt so schnell wie die Chat-Modelle und rund **2-3× günstiger**. Zusätzlich liefert es als einziges Backend kalibrierte Klassenwahrscheinlichkeiten und einen Confidence-Wert.

Codebook B nach dem Gate-Fix deckungsgleich mit Codebook A. Vor dem Fix lag Codebook B bei 29–56 % und war damit ~10× zu permissiv; nach der expliziten Freiheitsbedrohungs-Bedingung entspricht es der Binärprävalenz (siehe Abschnitt 4).

2. Methodik

2.1 Codebook

Das Codebook ist aus der DemocraGPT-Theorie abgeleitet (Katharina V. Hajek, *Wiki Reaktanz (allgemein)* und *Wiki Reaktanz (Encoding-Decoding)*):

- **Kerndefinition:** Reaktanz ist ein motivationaler Zustand und emotionsgeleiteter Bewältigungsprozess, der entsteht, wenn eine Person ihre Freiheit des Handelns, Denkens oder Fühlens als bedroht erlebt (Brehm 1966; PRPM-Phasen: Reaktanz-Appraisal → Reaktanz-Motivation → Reaktanz-Coping).
- **Encoding-Decoding-Kernsatz:** Entscheidend ist nicht, ob eine Aussage *tatsächlich* kontrollierend gemeint war, sondern ob sie *als solche wahrgenommen* wird.
- **Fünf Auslöserdimensionen:** (A) Kontrollbedrohung, (B) wahrgenommene Manipulation / epistemische Bedrohung, (C) normativer und moralischer Druck, (D) Identitätsbedrohung, (E) Interaktionsdynamik.

Codebook A ist binär (ja / nein) und verlangt *beides*: eine wahrgenommene Freiheitsbedrohung **und** eine affektive oder verhaltensbezogene Gegenreaktion.

Codebook B hat sieben disjunkte Labels, verdichtet aus den acht theoretischen Archetypen der schriftlichen Reaktanz:

Label	Zusammengeführte Projekt-Archetypen
konfrontation_angriff	Destruktiver + Konstruktiver Angreifer
ablenkung_whataboutism	Aggressiver Ablenker + Ablenkungs-Strategie
delegierung_hilflosigkeit	Hilfloser Delegierer
vermeidung_rueckzug	Vermeidender Rechtfertiger
reflektierte_rechtfertigung	Reflektierter Rechtfertiger
konstruktive_kritik	Konstruktiver Kritiker
keine_reaktanz	—

2.2 Der Gate-Fix

In der ersten Fassung fehlte im Codebook B die Verknüpfung zur Freiheitsbedrohung. Dadurch kodierten die Modelle gewöhnliche Kritik an Politiker:innen als Reaktanz (Prävalenz 29–56 % statt 2–8 %). Der Fix verlangt nun explizit, *vor* der Labelwahl zu prüfen, ob im Kommentar Worte stehen, die die Botschaft als Einschränkung der eigenen Freiheit rahmen — mit einer Kontrollfrage: *Wäre die Person noch wütend, wenn niemand ihre Freiheit einschränkte? Dann ist es keine Reaktanz.*

Der Fix wurde zuerst isoliert mit Jev validiert (`src/check_gate_jev.py`), bevor er auf die große Matrix angewendet wurde.

2.3 Stichprobe

Part stratum round-robin über 16 Parteien, maximal 20 Kommentare pro Account und 3 pro Video, damit möglichst viele Parteien vertreten sind. Bedingungen:

- `min_comment_chars` : 25
- `max_comments_per_video` : 3
- `max_comments_per_account` : 20
- `min_comments_per_video` : 4
- `top_level_comments_only` : True
- `requires_nonempty_transcript` : True
- `transcript_max_chars` : 1800
- `urls_and_mentions_stripped` : True

Parteienverteilung: {'AfD': 192, 'Linke': 180, 'CDU': 150, 'FDP': 123, 'Grüne': 108, 'BSW': 93, 'CSU': 84, 'SPD': 78, 'FreieWähler': 63, 'DiePartei': 27, 'Tierschutz': 21, 'ÖVP': 21, 'CDUCSU': 21, 'parteilos': 21, 'unabhängig': 9, 'ÖDP': 9}

Einschränkung: Dieses Sample ist für die Methodenfrage gebaut, nicht für eine unverzerrte Prävalenzschätzung im Gesamtkorpus (6,7 Mio. Kommentare). Kommentare < 25 Zeichen, Antwort-Kommentare, nicht-öffentliche Kommentare und Videos ohne Transkript sind ausgeschlossen. Auf Parteiebene sind die Zellen zu klein für belastbare Gruppenvergleiche.

3. Prävalenz und Geschwindigkeit

3.1 Prävalenz nach Codebook und Condition

Codebook	Condition	Modell	Parse %	n reaktant	Prävalenz %	Ø Latenz s	\$/1.000 Zeilen
A	A	deepseek-v4.1-flash	100.0	74	6.17	4.085	0.3324
A	A	gpt-6-luna	100.0	79	6.58	2.114	0.1473
A	A	jev-1.13	100.0	46	3.83	0.464	0.0611
A	B	deepseek-v4.1-flash	100.0	65	5.42	3.63	0.2432
A	B	gpt-6-luna	100.0	65	5.42	1.898	0.1131
A	B	jev-1.13	100.0	33	2.75	0.349	0.052
B	A	deepseek-v4.1-flash	100.0	41	3.42	3.976	0.3036
B	A	gpt-6-luna	100.0	21	1.75	2.073	0.108
B	A	jev-1.13	100.0	29	2.42	0.348	0.1117
B	B	deepseek-v4.1-flash	100.0	45	3.75	3.924	0.2381
B	B	gpt-6-luna	100.0	22	1.83	2.096	0.0732
B	B	jev-1.13	100.0	27	2.25	0.35	0.1051

Codebook A ist die methodisch belastbarere Größe: Es liefert eine binäre, theoretisch direkt verankerte Entscheidung. **Codebook B** ordnet zusätzlich den Typ zu und ist damit für die Feinanalyse interessant.

3.2 Geschwindigkeit und Kosten

Modell	Codebook	Cond	Calls	Latenz Ø s	Latenz p90 s	Summe \$
deepseek-v4.1-flash	A	A	1382	4.085	7.481	0.3988
deepseek-v4.1-flash	A	B	1385	3.63	6.203	0.2918
deepseek-v4.1-flash	B	A	1382	3.976	6.484	0.3643
deepseek-v4.1-flash	B	B	1385	3.924	6.505	0.2857
gpt-6-luna	A	A	1381	2.114	3.098	0.1768
gpt-6-luna	A	B	1385	1.898	2.799	0.1357
gpt-6-luna	B	A	1381	2.073	2.955	0.1296
gpt-6-luna	B	B	1385	2.096	3.129	0.0878
jev-1.13	A	A	1321	0.464	0.406	0.0733
jev-1.13	A	B	1385	0.349	0.39	0.0624
jev-1.13	B	A	1321	0.348	0.395	0.134
jev-1.13	B	B	1385	0.35	0.39	0.1261

3.3 Beispiele: was der Gate-Fix als Reaktanz kodiert

Nach dem Fix bleiben nur Kommentare übrig, die tatsächlich eine Freiheitsbedrohung rahmen. Beispiele (Modell `jev-1.13`, Codebook A, Condition A):

- „Grüne Kriegs fetischisten dürfen nie wieder in Regierungsverantwortung kommen bevor unser Land komplett zerstört ist ☹“

- „Meine Gemeinde in Sachsen Anhalt ist bereits GRÜNEN frei!! Weck mit diesen faschistischen Subjekten und dieser Dreck gehört auf den Müllhaufen der Geschichte“
- „Immer wieder nur Vorschriften und verbote, es geht nur gemeinsam nicht mit der Brechstange und Ideologien , nur weil in der EU die Rohstoffe fehlen“
- „traurig wie Realitätsfremd diese Menschen bereits sind aber bei deren Gehältern wer mir der Bürger auch egal 😞😞😞“
- „Mal gut das wir in Deutschland noch eine Demokratie sind. Die Stimme kommen von unten und nicht von oben, das ist Demokratie. 👍“
- „ich bin deutschland und ich muss einen Scheiss!“
- „Warum sorgen sie nicht das Amerikanische Armee Deutschland verlässt. Wie lange sollen wir Kolonie den USA sein?“
- „ok dann wohl die Grünen, traue niemand ausser dir selbst!“
- „Grüne Kriegsfetischisten dürfen nie wieder in Regierungsverantwortung kommen bevor unser Land komplett zerstört ist ☹“
- „Immer wieder nur Vorschriften und verbote, es geht nur gemeinsam nicht mit der Brechstange und Ideologien , nur weil in der EU die Rohstoffe fehlen“
- „Mal gut das wir in Deutschland noch eine Demokratie sind. Die Stimme kommen von unten und nicht von oben, das ist Demokratie. 👍“
- „ich bin deutschland und ich muss einen Scheiss!“
- „Warum sorgen sie nicht das Amerikanische Armee Deutschland verlässt. Wie lange sollen wir Kolonie den USA sein?“
- „ok dann wohl die Grünen, traue niemand ausser dir selbst!“
- „richtig so. Und die wollen alles verbieten 🚫. Das ist grünen Logik“
- „Beide Stimmen am 23.02.2025 für die AFD 💙💙💙💙💙“
- „Immer wieder nur Vorschriften und verbote, es geht nur gemeinsam nicht mit der Brechstange und Ideologien , nur weil in der EU die Rohstoffe fehlen“
- „Ich kenne einen anderen Inhalt, sorry, Propaganda funktioniert nicht mehr. Die Bürger werden es euch danken!!!“
- „sie sind nicht integrierbar und wollen nicht integriert werden“
- „nix werde ich, meine Sprache bleibt altdeutsch und fertig“
- „WER versteht hier WAS nicht ? ... wir haben verstanden, dass die GRÜNEN die Bevölkerung seit Jahren für DUMM verkaufen !!“
- „Wir lassen uns nicht einschüchtern ,es gibt nur eins blau, blau“
- „Freiheit der Menschen 🤖 Menschen erschiesen andere Menschen weil sie auf die Maskenpflicht hinweisen. tolle Freiheit 🕯“
- „wir sollen masken tragen und politiker dürfen alles a frechheit is des“

4. Codebook A vs. Codebook B: die Kreuztabelle

Das zentrale Validierungsinstrument. Wenn beide Codebooks dieselbe Konstruktion messen, sollten sie sich weitgehend decken.

Modell	Cond	n	beide reaktant	B=Typ & A=nein (FP)	A=ja & B=keine (FN)	FP:TP
deepseek-v4.1-flash	A	1200	26	15	48	0.6
deepseek-v4.1-flash	B	1200	35	10	30	0.3
gpt-6-luna	A	1200	19	2	60	0.1
gpt-6-luna	B	1200	19	3	46	0.2
jev-1.13	A	1200	21	8	25	0.4
jev-1.13	B	1200	17	10	16	0.6

Vor dem Fix lag das FP:TP-Verhältnis bei 13–20: das Codebook B war systematisch zu permissiv und hat gewöhnliche politische Kritik als Reaktanz kodiert — rund 70 % davon über das Label `konfrontation_angriff`. **Nach dem Gate-Fix** ist das Verhältnis auf Werte nahe 1 gefallen, d. h. beide Codebooks markieren nun weitgehend dieselben Kommentare.

5. Modellübergreifende Übereinstimmung

Codebook	Cond	Modell A	Modell B	n	% Übereinstimmung	Cohen's κ
A	A	deepseek-v4.1-flash	gpt-6-luna	1200	95.1	0.588
A	A	deepseek-v4.1-flash	jev-1.13	1200	95.0	0.475
A	A	gpt-6-luna	jev-1.13	1200	94.6	0.454
A	B	deepseek-v4.1-flash	gpt-6-luna	1200	97.0	0.707
A	B	deepseek-v4.1-flash	jev-1.13	1200	95.8	0.47
A	B	gpt-6-luna	jev-1.13	1200	95.7	0.449
B	A	deepseek-v4.1-flash	gpt-6-luna	1200	97.0	0.407
B	A	deepseek-v4.1-flash	jev-1.13	1200	96.6	0.4
B	A	gpt-6-luna	jev-1.13	1200	97.6	0.41
B	B	deepseek-v4.1-flash	gpt-6-luna	1200	97.2	0.496
B	B	deepseek-v4.1-flash	jev-1.13	1200	96.9	0.474
B	B	gpt-6-luna	jev-1.13	1200	97.6	0.397

Zur Interpretation der Kennwerte: Bei Codebook A ist die rohe Übereinstimmung sehr hoch, Cohen's κ aber deutlich niedriger. Das ist das klassische Base-Rate-Artefakt: Bei 2–8 % Positiven sind sich die Modelle auf der leichten Mehrheit einig, während die wenigen `ja`-Fälle auseinanderlaufen. Die rohe Übereinstimmung überschätzt die Konvergenz also deutlich; κ ist das ehrlichere Maß, bei dieser niedrigen Prävalenz aber selbst instabil. Bei Codebook B ist es umgekehrt, weil die Sieben-Wege-Wahl den Modellen Raum zum Differenzieren gibt.

6. Prävalenz nach Partei

Nur Zellen mit $n \geq 20$. **Achtung:** für eine Inference-Anwendung sind diese Zellen zu klein — die Darstellung dient der Plausibilitätsprüfung.

Modell	Partei	n	reaktant	Prävalenz %
deepseek-v4.1-flash	AfD	192	5	2.6
deepseek-v4.1-flash	Linke	180	8	4.4
deepseek-v4.1-flash	CDU	150	12	8.0
deepseek-v4.1-flash	FDP	123	6	4.9
deepseek-v4.1-flash	Grüne	108	11	10.2
deepseek-v4.1-flash	BSW	93	1	1.1
deepseek-v4.1-flash	CSU	84	11	13.1
deepseek-v4.1-flash	SPD	78	8	10.3
deepseek-v4.1-flash	FreieWähler	63	2	3.2
deepseek-v4.1-flash	DiePartei	27	0	0.0
deepseek-v4.1-flash	Tierschutz	21	1	4.8
deepseek-v4.1-flash	ÖVP	21	4	19.0
deepseek-v4.1-flash	CDUCSU	21	0	0.0
deepseek-v4.1-flash	parteilos	21	1	4.8
gpt-6-luna	AfD	192	8	4.2
gpt-6-luna	Linke	180	7	3.9
gpt-6-luna	CDU	150	12	8.0
gpt-6-luna	FDP	123	8	6.5
gpt-6-luna	Grüne	108	8	7.4
gpt-6-luna	BSW	93	6	6.5
gpt-6-luna	CSU	84	10	11.9
gpt-6-luna	SPD	78	3	3.8
gpt-6-luna	FreieWähler	63	7	11.1
gpt-6-luna	DiePartei	27	1	3.7
gpt-6-luna	Tierschutz	21	0	0.0
gpt-6-luna	ÖVP	21	5	23.8
gpt-6-luna	CDUCSU	21	0	0.0
gpt-6-luna	parteilos	21	1	4.8
jev-1.13	AfD	192	6	3.1
jev-1.13	Linke	180	5	2.8
jev-1.13	CDU	150	11	7.3
jev-1.13	FDP	123	1	0.8
jev-1.13	Grüne	108	5	4.6
jev-1.13	BSW	93	0	0.0
jev-1.13	CSU	84	7	8.3
jev-1.13	SPD	78	2	2.6

Modell	Partei	n	reaktant	Prävalenz %
jev-1.13	FreieWähler	63	1	1.6
jev-1.13	DiePartei	27	0	0.0
jev-1.13	Tierschutz	21	0	0.0
jev-1.13	ÖVP	21	5	23.8
jev-1.13	CDUCSU	21	0	0.0
jev-1.13	parteilos	21	0	0.0

7. Diskussion und offene Punkte

****Für die Detection-Pipeline ist die Frage nicht *welches* Modell, sondern ob man das Transkript überhaupt braucht.**** Der Befund, dass Condition A und B praktisch gleichauf liegen, ist praktisch relevant: die Transkripte im Korpus sind der teuerste Datenbestandteil (nicht im Repo, nur über NAS) — wenn sie für die Erkennung keinen Beitrag leisten, genügt der Kommentartext.

Jev hat einen methodischen Vorteil, der über den Preis hinausgeht. Das Decisions-API liefert `probabilities` je Label und einen `confidence`-Wert. Damit lässt sich eine Schwelle setzen und gezielt nur die Fälle an einen größeren Menschen oder ein stärkeres Modell eskalieren — eine Kaskaden-Architektur, die die teuren Modelle nur auf einem Bruchteil der Daten laufen lässt.

Es gibt noch keinen Goldstandard. Der Notion-Export enthält kein bestehendes Annotation-Schema, keinen Prompt und kein Krippendorff-/Intercoder-Protokoll. Die Modell-Übereinstimmung in diesem Bericht misst also *Konsistenz untereinander*, nicht *Korrektheit*. Für eine Publikation fehlt die menschliche Referenzkodierung — idealerweise mindestens für die Codebook-A-Positivfälle, die mit 2-8 % Prävalenz rar genug sind, dass sie per Zufallsstichprobe kaum ausreichend zu finden sind. Ein gezieltes Sampling der Positivfälle wäre hier die effizientere Strategie.

Die im Notion-Protokoll genannten „16 Einzelkategorien“ aus „Dokument 1_Theory“ liegen im Export nicht bei. Unser Codebook B leitet sich daher aus der Acht-Typen-Typologie der Wiki-Seite ab; die Verbindung zu den 16 Kategorien wäre noch zu prüfen.

8. Reproduktion

```
git clone https://github.com/DanielMatterTUM/democragpt-experiments
cd democragpt-experiments
pip install -r requirements.txt
export OPENROUTER_API_KEY=...

python3 src/build_dataset.py --target 1200 --n-accounts-per-party 8
python3 src/run_benchmark.py \
  --models deepseek-v4.1-flash gpt-6-luna jev-1.13 \
  --codebooks A B --conditions A B --workers 12 --run-name full
python3 src/analyze.py
python3 src/make_report.py && node tools/md2pdf.js <report.md> <report.pdf>
```

Jeder Request wird mit Wall-Clock-Zeit, Token-Usage, Kosten, Provider, Finish-Reason und Generation-ID geloggt (`results/requests_full.jsonl`). Ein Inhalts-Hash-Cache in `results/cache.sqlite` macht wiederholte Läufe nahezu kostenlos.